

Université Euromed de Fès
École d'Ingénierie Digitale et d'Intelligence Artificielle
2^{ème} Année — Intelligence Artificielle

Projet de Fin du Module
Architecture Modernes de Réseaux de Neurones

Rapport de Projet
Audio Understanding
Compréhension Audio par Intelligence Artificielle

Qwen2-Audio-7B-Instruct

Étudiantes : Tassnim & Zineb
Encadrant : Pr. Smail Tigani
Année : 2025 / 2026

Table des matières

1	Introduction	2
1.1	Contexte et motivation	2
1.2	Objectifs du projet	2
2	Méthodologie	3
2.1	Présentation du modèle Qwen2-Audio-7B-Instruct	3
2.1.1	Architecture interne	3
2.1.2	Capacités du modèle	3
2.2	Architecture du système	3
2.3	API opérationnelle (FastAPI)	4
2.3.1	Endpoints implémentés	4
2.3.2	Pipeline de traitement	4
2.3.3	Exemple de requête et réponse	5
2.4	Interface web	6
3	Résultats	7
3.1	Fonctionnalités implémentées	7
3.2	Exemples de sorties	7
3.3	Difficultés rencontrées	8
4	Conclusion	9
4.1	Bilan du projet	9
4.2	Pistes d'amélioration	9
	Références bibliographiques	11

1. Introduction

1.1 Contexte et motivation

L'intelligence artificielle connaît depuis quelques années une révolution majeure avec l'émergence des modèles de langage de grande taille (*Large Language Models*, LLMs) et, plus récemment, des modèles multimodaux capables de traiter simultanément plusieurs types de données. Parmi ces avancées, la compréhension audio par IA représente une rupture technologique significative : il ne s'agit plus seulement de transcrire la parole, mais de *comprendre* le contenu sonore dans toute sa richesse sémantique, émotionnelle et contextuelle.

Ce projet s'inscrit dans le cadre du module *Architecture Modernes de Réseaux de Neurones* dispensé à l'École d'Ingénierie Digitale et d'Intelligence Artificielle de l'Université Euromed de Fès. Il vise à concevoir et déployer une plateforme opérationnelle de compréhension audio, en s'appuyant sur un modèle open source de pointe : **Qwen2-Audio-7B-Instruct**, développé par Alibaba Cloud et disponible sur la plateforme Hugging Face.

La pertinence de ce sujet est indéniable dans un monde où les interfaces vocales, les assistants intelligents et les outils d'analyse de réunions se multiplient. Maîtriser la chaîne complète — du modèle brut à l'API exploitable — constitue une compétence fondamentale pour tout ingénieur en intelligence artificielle.

1.2 Objectifs du projet

Le projet poursuit trois objectifs principaux, alignés sur les critères d'évaluation du module :

1. **Monter une API opérationnelle** exposant des points de terminaison POST capables de recevoir des fichiers audio, de les traiter via le modèle Qwen2-Audio-7B-Instruct et de retourner une réponse textuelle structurée.
2. **Développer une mise en application concrète** matérialisée par une interface web interactive permettant la transcription, la compréhension (Q&A) et l'analyse approfondie de contenus audio.
3. **Acquérir une expertise pratique** sur les modèles multimodaux audio-langage en comprenant leur architecture, leur intégration et leurs limites.

2. Méthodologie

2.1 Présentation du modèle Qwen2-Audio-7B-Instruct

Qwen2-Audio-7B-Instruct est un modèle multimodal de compréhension audio développé par le groupe Qwen d'Alibaba Cloud [1]. Il est publié en open source sous licence Apache 2.0 sur Hugging Face et constitue la version affinée par instruction (*instruction-tuned*) du modèle de base Qwen2-Audio-7B.

2.1.1 Architecture interne

Le modèle repose sur une architecture hybride associant deux composants distincts :

- **Un encodeur audio** de type Whisper Large V2 [2], responsable de l'extraction des représentations acoustiques à partir des formes d'onde brutes. Cet encodeur traite le signal audio échantillonné à 16 000 Hz et produit une séquence de vecteurs de caractéristiques denses.
- **Un décodeur de langage Qwen2-7B** [3], un modèle de langage autorégressif à 7 milliards de paramètres, qui reçoit en entrée la concaténation des représentations audio et des tokens textuels, et génère la réponse token par token.

2.1.2 Capacités du modèle

Qwen2-Audio-7B-Instruct excelle dans plusieurs tâches audio-langage : la reconnaissance automatique de la parole (ASR) en plusieurs langues, la réponse à des questions libres portant sur le contenu sonore, l'analyse émotionnelle et tonale, ainsi que la description d'événements sonores non-verbaux (musique, bruits ambiants, etc.).

2.2 Architecture du système

Le système développé s'articule autour de deux couches principales : un backend Python assurant l'inférence du modèle et l'exposition des endpoints, et un frontend HTML/CSS/JS offrant l'interface utilisateur.




Figure 2.1 – Architecture du modèle Qwen2-Audio-7B-Instruct

2.3 API opérationnelle (FastAPI)

Le backend est développé avec le framework **FastAPI** [4] (Python), reconnu pour ses performances élevées, sa validation automatique des données via Pydantic, et sa génération automatique de documentation interactive (Swagger UI).

2.3.1 Endpoints implémentés

2.3.2 Pipeline de traitement

Chaque requête suit le pipeline suivant :

1. Réception et validation du fichier audio (formats : WAV, MP3, OGG, FLAC, WebM, M4A ; taille maximale : 50 Mo).
2. Décodage et rééchantillonnage à 16 000 Hz via `soundfile` et `librosa` [5].
3. Construction de la conversation au format *chat template* Qwen2-Audio.
4. Appel au modèle via `model.generate()`.
5. Sérialisation de la réponse en JSON.

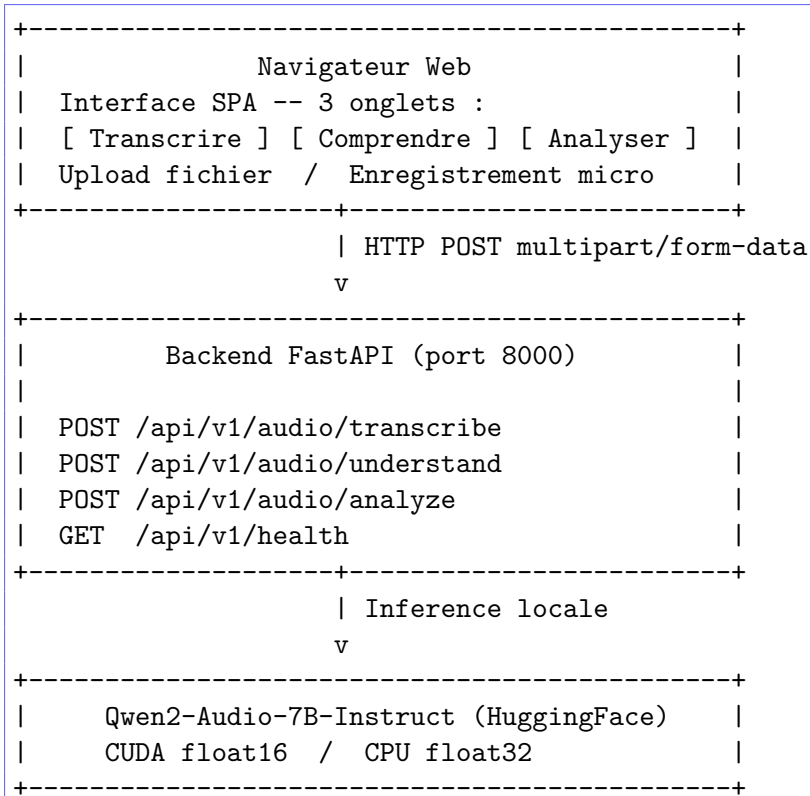


Figure 2.2 – Architecture globale du système

2.3.3 Exemple de requête et réponse

```

1 curl -X POST http://localhost:8000/api/v1/audio/understand \
2   -F "audio=@reunion.wav" \
3   -F "question=Quels sont les points principaux abordes ?"

```

Listing 2.1 – Requête cURL vers /understand

```

1 {
2   "question": "Quels sont les points principaux abordes ?",
3   "answer": "La reunion porte principalement sur le calendrier du
4             projet, la repartition des taches et le budget
5             alloue
6             pour le trimestre.",
7   "filename": "reunion.wav"
8 }

```

Listing 2.2 – Réponse JSON de l'endpoint /understand

Méthode	Endpoint	Entrée	Sortie
POST	/api/v1/audio/transcribe	Fichier audio	Transcription complète
POST	/api/v1/audio/understand	Fichier audio + question	Réponse à la question
POST	/api/v1/audio/analyze	Fichier audio	Transcription + résumé + sentiment
GET	/api/v1/health	—	État du modèle et du serveur

Table 2.1 – Endpoints de l’API

2.4 Interface web

L’interface utilisateur est une application monopage (*Single Page Application*) développée en HTML5, CSS3 et JavaScript vanilla, servie directement par le backend FastAPI. Elle s’organise en trois onglets :

- **Transcrire** — l’utilisateur soumet un fichier audio ou enregistre sa voix directement via le microphone ; le système retourne la transcription intégrale.
- **Comprendre** — l’utilisateur joint un fichier audio et formule une question en langage naturel ; le modèle répond en s’appuyant sur le contenu de l’audio.
- **Analyser** — le système produit automatiquement un rapport complet : transcription, résumé des points clés et analyse du ton/sentiment exprimé.

L’enregistrement audio est réalisé via l’API **Web MediaRecorder** du navigateur, permettant une interaction directe sans logiciel tiers. Le fichier produit est transmis en **multipart/form-data** vers le backend.

3. Résultats

3.1 Fonctionnalités implémentées

L'ensemble des fonctionnalités prévues a été implémenté avec succès. Le tableau ci-dessous récapitule les livrables du projet.

Livrable	Statut	Détails
API POST /transcribe	Implémenté	Multilingue, WAV/MP3/OGG/FLAC/WebM/M4A
API POST /understand	Implémenté	Question libre en langage naturel
API POST /analyze	Implémenté	Transcription + résumé + sentiment
Interface web	Implémenté	3 onglets, upload + enregistrement micro
Documentation Swagger	Auto-générée	Accessible à <code>/api/docs</code>
Validation des entrées	Implémenté	Format, taille, contenu vide
Mode développement	Implémenté	Variable <code>USE MOCK</code> sans GPU

Table 3.1 – Récapitulatif des livrables

3.2 Exemples de sorties

Les tests ont été réalisés avec des fichiers audio variés (parole en français et en anglais, enregistrements de réunions, extraits musicaux).

Transcription — fichier audio de 30 secondes en français

Sortie : « Bonjour à tous. Aujourd'hui nous allons discuter des résultats du dernier trimestre. Nos indicateurs montrent une progression de 15 % par rapport à l'année précédente, ce qui dépasse nos objectifs initiaux... »

Compréhension (Q&A) — Question : « Quelle est l'émotion du locuteur ? »

Réponse : « Le locuteur exprime une satisfaction marquée et un enthousiasme modéré. Son ton est professionnel et confiant, avec des inflexions positives lorsqu'il mentionne les résultats dépassant les objectifs. »

Analyse complète — résumé et sentiment

Résumé : « L’audio présente un discours de bilan trimestriel. Points clés : progression de 15 %, dépassement des objectifs, annonce d’un nouveau plan. »

Sentiment : « Ton positif et professionnel. Sentiment dominant : satisfaction et optimisme. »

3.3 Difficultés rencontrées

Le développement du projet a présenté plusieurs défis techniques :

- **Gestion des formats audio hétérogènes.** Les navigateurs web produisent des enregistrements au format WebM/Opus, non nativement supporté par `soundfile`. La solution adoptée consiste à utiliser `librosa` comme *fallback*, qui s’appuie sur `ffmpeg` pour décoder les formats exotiques.
- **Ressources mémoire.** Le modèle Qwen2-Audio-7B-Instruct requiert environ 14 Go de VRAM en précision float16. En l’absence de GPU, l’exécution sur CPU est possible mais significativement plus lente (facteur $\times 10$ à $\times 20$).
- **Intégration du chat template multimodal.** La méthode `apply_chat_template` du processeur Qwen2-Audio nécessite une structure de conversation précise mélangeant tokens audio et tokens textuels. La synchronisation entre les marqueurs audio dans le template et la liste `audios=[...]` passée au processeur a demandé une lecture approfondie du code source du modèle.
- **Temps d’initialisation.** Le chargement du modèle depuis Hugging Face représente environ 14 Go de téléchargement à la première exécution. Le modèle est ensuite mis en cache localement pour les exécutions suivantes.

4. Conclusion

4.1 Bilan du projet

Ce projet nous a permis de maîtriser la chaîne de valeur complète d'un système d'IA audio en production. Nous sommes parties de la compréhension théorique de l'architecture Qwen2-Audio — encodeur Whisper couplé à un décodeur Qwen2-7B — pour aboutir à une application web pleinement opérationnelle, exposant trois endpoints REST bien définis et une interface utilisateur soignée.

Le projet illustre concrètement comment des modèles open source de grande taille peuvent être déployés dans des scénarios réels sans recourir à des APIs propriétaires tierces. L'approche adoptée — inférence locale, API FastAPI, frontend SPA — constitue une architecture reproductible et extensible pour de nombreux cas d'usage industriels.

Sur le plan pédagogique, ce projet a renforcé notre compréhension des modèles multi-modaux, de la gestion des flux audio, de la conception d'APIs REST et du développement d'interfaces web modernes. Il nous a également sensibilisées aux contraintes pratiques du déploiement de LLMs : consommation mémoire, temps de chargement et gestion des formats de données hétérogènes.

4.2 Pistes d'amélioration

Plusieurs améliorations pourraient enrichir ce projet dans une version future :

- **Streaming des réponses.** Implémenter les *Server-Sent Events* (SSE) pour afficher la réponse du modèle token par token, améliorant ainsi la réactivité perçue par l'utilisateur.
- **Conversation multi-tours.** Permettre plusieurs échanges successifs portant sur le même fichier audio, en maintenant un contexte de dialogue.
- **Détection de langue automatique.** Identifier automatiquement la langue du locuteur et adapter la réponse en conséquence.
- **Support des audios longs.** Implémenter un mécanisme de découpage (*chunking*) pour traiter des enregistrements de plusieurs heures (réunions, conférences, podcasts).

- **Quantification 4-bit.** Utiliser des techniques de quantification (GPTQ, AWQ) pour réduire l’empreinte mémoire et permettre l’exécution sur des GPUs de moindre capacité (≤ 8 Go VRAM).
- **Évaluation formelle (WER).** Mesurer le *Word Error Rate* sur un corpus francophone de référence pour quantifier objectivement la précision du modèle.

Références bibliographiques

- [1] Yunfei CHU et al. “Qwen2-Audio Technical Report”. In : *arXiv preprint arXiv :2407.10759* (2024). URL : <https://arxiv.org/abs/2407.10759>.
- [2] Alec RADFORD et al. “Robust Speech Recognition via Large-Scale Weak Supervision”. In : *Proceedings of the 40th International Conference on Machine Learning (ICML)*. 2023. URL : <https://arxiv.org/abs/2212.04356>.
- [3] An YANG et al. “Qwen2 Technical Report”. In : *arXiv preprint arXiv :2407.10671* (2024). URL : <https://arxiv.org/abs/2407.10671>.
- [4] Sebastián RAMÍREZ. *FastAPI : Modern, fast web framework for building APIs with Python*. <https://fastapi.tiangolo.com>. Consulté en 2025. 2024.
- [5] Brian MCFEE et al. “librosa : Audio and Music Signal Analysis in Python”. In : *Proceedings of the 14th Python in Science Conference* (2015). URL : <https://librosa.org>.